PARTIE 1 : TEXTE POUR LE FICHIER README.md

Projet UE Data Mining (M2 Data Science - 2026/2027)

Nom du groupe : G10

Membres du groupe :

MAHAMOUD GUEDI Idil

Présentation de notre démarche

Dans le cadre de ce projet de Data Mining, notre objectif est de retrouver le fil conducteur et le secret caché à travers les quatre dossiers de données mis à notre disposition (health, ecology, logistics et public_records). Pour travailler efficacement en groupe sans nous perdre dans la masse d'informations, on a décidé de diviser notre travail en deux grandes étapes. D'abord, nous avons nettoyé et exploré chaque dossier séparément afin d'avoir des bases de données propres, que nous avons sauvegardées dans le dossier data_cleaned/ . Ensuite, nous avons croisé ces tables nettoyées en utilisant les méthodes vues en cours (statistiques descriptives, réduction de dimension avec la PCA, clustering K-Means, analyse de séries temporelles et fouille de textes) pour faire ressortir les anomalies et comprendre l'histoire globale.

Ce que nous avons fait sur le dossier Health (notebook_health.ipynb)

Dans le notebook consacré à la santé, nous avons traité les 7 fichiers médicaux provenant des cliniques et des hôpitaux. On a commencé par un gros travail de nettoyage car les fichiers bruts contenaient plusieurs pièges classiques : quelques lignes en doublon, des espaces en trop dans les textes, des majuscules mélangées aux minuscules et des formats de dates différents. Le point le plus important a été de nettoyer la colonne des valeurs numériques dans clinical_observations.csv, où 340 mesures avaient des virgules à la place des points ou contenaient le nom de l'unité collé au chiffre . En écrivant une petite fonction de nettoyage, on a pu récupérer toutes ces valeurs sans rien perdre.

Une fois les tables propres et exportées dans data_cleaned/health/, nous les avons regroupées autour de l'identifiant unique des patients pour créer un tableau récapitulatif de nos 240 patients et tracer une matrice de corrélation. Cette étape nous a permis de découvrir deux choses très importantes. Premièrement, grâce à la PCA et au clustering K-Means, on a isolé un groupe de 10 patients très particuliers qui ont un écart anormal entre leur rythme cardiaque à la poitrine et leur pouls au poignet, une démarche qui balance sur les côtés tout en gardant un super équilibre, des mouvements des yeux indépendants et des soucis récurrents sur les caméras thermiques et de reconnaissance faciale. En analysant leurs signaux cardiaques bruts avec une Transformée de Fourier (FFT), on a même vu qu'ils avaient deux fréquences cardiaques en même temps, comme s'ils avaient deux cœurs, ce qui est confirmé par les 4 notes médicales secrètes que nous avons isolées avec la méthode TF-IDF. Deuxièmement, nous avons remarqué que 8 hauts dirigeants politiques et économiques recevaient régulièrement des injections d'un protocole restreint appelé MRP-42, ce qui fait baisser leur âge biologique d'environ 11 ans par rapport à leur vrai âge.

Il nous reste maintenant à fouiller les dossiers (logistics,ecology et public_records) pour découvrir d'où vient ce fameux produit MRP-42 et qui sont vraiment ces 10 patients aux caractéristiques de caméléon.

PARTIE 2 : TEXTES EXPLICATIFS ET CONCLUSIONS POUR LE NOTEBOOK HEALTH

Dans ce notebook, nous allons analyser les 7 fichiers du dossier data/health/. Avant de chercher des anomalies ou de faire du Machine Learning, on commence par nettoyer chaque table une par une. C'est une étape indispensable car si on laisse des doublons, des fautes de frappe ou des chiffres mal formatés, nos moyennes et nos graphiques seront faussés. Après ce nettoyage, on sauvegardera nos tables propres dans le dossier data_cleaned/health/, puis on les rassemblera pour étudier les liens entre les patients, leurs symptômes et les traitements qu'ils reçoivent.

Nettoyage de patient_administration.csv :

On commence par la table principale qui contient l'identité des patients. En regardant les données avec describe() et duplicated(), on voit qu'il n'y a pas de valeurs manquantes mais qu'une patiente (PAT-31045) a été enregistrée deux fois. On supprime donc ce doublon pour garder nos 240 vrais patients. On nettoie aussi le texte car certaines régions ou professions ont des espaces en trop ou des majuscules inversées (par exemple : vALENNE rEPUBLIC), et on remet

toutes les dates au même format standard. En observant les premières lignes du tableau, on remarque déjà que les 10 premiers patients sont tous des chercheurs ou des conseillers, et que juste en dessous (lignes 10 à 17), on retrouve 8 grands dirigeants politiques et chefs d'entreprises.

Nettoyage de clinical_encounters.csv :

Cette deuxième table regroupe toutes les visites médicales. Ici aussi, on enlève les 2 lignes en doublon pour obtenir 1 067 consultations uniques, et on remplace les 3 sources d'orientation manquantes par "unknown". Quand on regarde les types de visites, on se rend compte qu'il y a 15 catégories différentes juste à cause de problèmes de majuscules et d'espaces. En mettant tout en minuscules proprement, on retombe sur 10 vrais types de visites. En croisant ces données, on remarque que 191 visites sont classées en secret renforcé (restricted), et qu'elles sont presque toutes gérées par seulement deux médecins (LIC-VLN-MED-1002 et LIC-VLN-MED-1001).

Nettoyage de clinical_procedures.csv :

Dans la table des actes médicaux, on supprime le doublon présent et on harmonise le texte et les dates comme pour les tables précédentes. On voit que la colonne material_reference est presque toujours vide, sauf sur 50 lignes précises. En regardant de plus près, on comprend que ce n'est pas un oubli : parmi les 7 actes médicaux possibles, seul le protocole MRP-42 utilise des lots de produits numérotés (MTL-...). Les 6 autres codes sont juste des examens classiques (imagerie, test d'équilibre, bilan des yeux). Mieux encore, sur les 50 doses de MRP-42, 30 doses sont données régulièrement aux 8 dirigeants politiques et économiques qu'on avait repérés au début, tandis que les 20 autres doses ont été données une seule fois à 20 patients classiques dans le cadre d'un test de recherche.

Nettoyage de clinical_observations.csv :

C'est la table la plus grande et la plus importante du dossier avec 17 734 mesures médicales après suppression des 2 doublons. En vérifiant les colonnes, on est tombés sur un vrai piège dans numeric_value : 340 mesures étaient écrites avec une virgule au lieu d'un point (comme "84,9") ou avaient l'unité collée au chiffre (comme "82.2 index"). Si on avait fait une conversion automatique classique, Python aurait effacé ces 340 valeurs en les remplaçant par du vide (NaN). Grâce à notre fonction clean_numeric, on a nettoyé ces textes avant de les convertir en nombres, ce qui nous a permis de garder 100 % des 15 864 mesures chiffrées.

Nettoyage de cardiac_recordings.csv et cardiac_signal_samples.csv :

Ces deux tables contiennent les informations sur les 44 enregistrements d'électrocardiogrammes (ECG) et les 96 925 points de mesures pris toutes les 10 millisecondes sur deux capteurs (Canal A et Canal B). Les tables n'ont ni doublons ni valeurs manquantes. En regardant la qualité des appareils (device_quality), on voit que le score est très bon partout (plus de 86 % en moyenne). On remarque pourtant que pour certains patients au repos, l'appareil indique un rythme bizarre ou un chevauchement de signaux (signal_overlap). Pour deux patients (PAT-31162 et PAT-31065), les médecins ont même refait le test le jour même en changeant de machine (technical_repeat), mais l'anomalie est restée, ce qui prouve que ça vient bien du corps des patients et pas d'un bug de l'appareil.

Nettoyage de clinical_notes.csv :

Ce dernier fichier contient 30 comptes-rendus écrits par les médecins. On supprime la colonne superseded_document_id car elle est totalement vide, puis on nettoie les colonnes de types et de confidentialité. En lisant les titres, on voit vite que 26 notes ont des titres numérotés très banals (de 01 à 26), alors que les 4 premières notes ont des titres précis et sont classées confidentielles ou restreintes.

Fusion du Panel et Matrice de Corrélation :

Maintenant que nos 7 tables sont propres et sauvegardées dans data_cleaned/health/, on les fusionne dans un seul tableau (panel) où chaque ligne représente un des 240 patients. On en profite pour créer deux variables très utiles : la différence entre le rythme cardiaque à la poitrine et le pouls au poignet (apical_ppulse_gap), et la différence entre l'âge réel du patient et son âge biologique estimé (bio_chrono_age_gap). Pour les signaux cardiaques, on utilise une Transformée de Fourier (FFT) afin de comparer la fréquence en battements par minute (BPM) du Canal A et du Canal B.

En affichant la matrice de corrélation, l'ACP et le clustering K-Means, tout devient beaucoup plus clair et on peut tirer notre conclusion générale sur le dossier Health :

Un groupe de 10 patients non-humains : Les 10 premiers patients de la base forment un groupe complètement à part

sur le graphique de la PCA. Chez eux, le cœur mesuré à la poitrine bat beaucoup plus vite que le pouls mesuré au poignet (+22 bpm d'écart en moyenne), et l'analyse FFT des signaux ECG montre qu'il y a en fait deux rythmes cardiaques différents en même temps. En plus de ce double battement, ces 10 personnes marchent en se balançant fortement sur les côtés tout en ayant un très bon équilibre, leurs yeux peuvent bouger de façon indépendante, et leur visage brouille régulièrement les caméras normales et thermiques. Quand on utilise TF-IDF pour trouver les 4 notes médicales qui sortent du lot parmi les 30 textes, on tombe justement sur des rapports qui parlent de (double structure cardiaque, de contrôle volontaire de l'apparence et d'un lien avec une personnalité publique appelée Elias Voss) .

Un traitement de rajeunissement (MRP-42) réservé aux élites : De l'autre côté, notre deuxième graphique montre très bien l'effet du protocole MRP-42. Les 8 grands dirigeants politiques et économiques qui ont reçu entre 3 et 5 doses de ce produit ont un âge biologique inférieur de 10 à 12 ans à leur vrai âge. C'est donc un traitement anti-âge très puissant qui nécessite des injections régulières, contrairement aux 20 citoyens classiques qui n'ont reçu qu'une seule dose de test et chez qui l'âge biologique n'a presque pas bougé.